

上证指数预测实验方法与结论

ARIMA LSTM PatchTST TimesFM 2.5

报告日期：2026年9月20日。实验行情截至2026年9月11日。研究对象为上证指数日线，重点检验模型能否预测下一交易日收盘，而不是仅仅画出贴近历史的曲线。

主要结论：复杂模型尚未稳定超过简单基准。 ARIMA改进后优于原版；PatchTST和TimesFM 2.5分别优于对应的LSTM，但三组主模型的整体点位误差都高于“下一日等于前日收盘”的基准。这个结论仅适用于已完成的实验设置与历史区间。




图1 按实验条件分别展示RMSE。各面板内部可以比较；ARIMA测试区间与后两组不同，后两组输入长度和训练方式也不同，不构成统一的架构排名。

方法	学习方式	本轮重点
ARIMA	传统统计时间序列模型	检查差分、阶数和训练窗口
LSTM	带门控记忆的循环神经网络	从课堂示例发展为逐日重训对照
PatchTST	把序列分片后使用Transformer	小模型在本地历史上从头训练
TimesFM 2.5	预训练时间序列Transformer	冻结官方权重直接预测

如何阅读这份报告

先看数据切分与预测任务，再看四个模型的方法、实际曲线与误差，最后看结论边界。表中的RMSE和MAE都以指数点为单位，越低越好。方向准确率与投资收益是不同评价对象。

一 数据与实验设计

同一行情快照 严格按时间取用历史信息

数据来自已保存的Yahoo Finance上证指数日线快照，代码为000001.SS。本文整理原有实验，不更新行情、不重新挑选测试日。后期配对实验统一使用Close；早期LSTM还探索过开盘价、最高价和成交量等输入。

实验	复核区间与样本	预测时已知的信息
ARIMA改进	2026-03-16至09-11 125个交易日	窗口内历史日对数收益 126条、252条或扩展窗口
PatchTST与LSTM	2026-06-15至09-11 64个交易日	此前两年训练 最近20个连续交易日输入
TimesFM与LSTM	2026-06-15至09-11 64个交易日	最近32日输入；LSTM用两年训练 TimesFM使用冻结预训练权重

训练历史和输入窗口分别决定什么

“两年训练历史”用于形成大量训练案例；“20日或32日输入”是每个案例所观察的近期长度。例如，为预测6月15日，LSTM只使用6月12日及以前的数据；32日输入覆盖4月27日至6月12日。到了下一个目标日，窗口随日期前移。

滚动单步预测的顺序

第一步，截取目标日前的真实历史。第二步，拟合或载入模型，并输出下一交易日预测。第三步，将预测与对应日期的真实收盘对齐评分。进入下一目标日后，才允许把刚发生的真实行情加入历史。图中的三个月预测线是64次单步预测的连接，并非一次预测未来三个月。

验证阶段如何与评分阶段分开

ARIMA的18个候选只在更早的2025-03-14至2026-03-13验证期选择。后期LSTM与PatchTST每天把历史窗口最后40个目标日作为内部验证，在最多40轮中选择轮数；随后重新初始化，在全部已知两年历史上重训。验证阶段的标准化不使用验证目标日的数据。TimesFM本轮不微调、不按测试误差挑选参数。

评价指标与基准

前日收盘基准：预测收盘 = 前一交易日实际收盘。

MAE：各日绝对误差的平均，表示通常偏离多少点。

RMSE：误差平方的平均再开平方，对较大的预测偏差更敏感。

这些日期已在此前研究中查看，因此本文称其为历史复核。时间切分可阻止当天真实值进入当天预测。反复研究同一时期仍可能带来选择偏差。

二 ARIMA实验

先检查差分 再比较少量参数和训练窗口

原理与目标：ARIMA用历史值和历史预测误差建立线性模型，d表示差分次数。本项目先计算日对数收益 $\log(\text{当日收盘} / \text{前日收盘})$ ，预测收益后用“前日收盘 $\times \exp(\text{预测收益})$ ”还原指数点位。原版ARIMA(5,1,0)每天扩展历史、重新拟合并预测次日。

改进方法：对收益再设 $d = 1$ 可能造成额外差分。用ADF、KPSS及自相关检查，再固定6种结构 $\times 3$ 种窗口，共18个候选；窗口为126条收益、252条收益或扩展窗口。只按更早验证期的点位RMSE选择，结果为ARIMA(0,0,0)含常数、252条收益窗口，实质是历史平均收益。




图2 半年125次逐日预测。上图为点位，下图为日对数收益。预测收益接近零时，还原后的点位仍会跟随前日收盘变化，点位曲线贴近并不代表抓住了次日涨跌。

方法	RMSE	MAE
原ARIMA(5,1,0)	45.20	35.34
选定252条收益均值	41.68	31.48
前日收盘基准	41.42	31.46

结论：相对原版RMSE下降7.79%，但比基准高0.63%。原实验的区块bootstrap结果也未确认相对基准的稳定优势。收益均值在125天中始终预测上涨，54.4%的方向准确率等于该时期上涨日比例，不能解释为学会了有效择时。

三 LSTM实验

从课堂循环网络示例到每日重训对照

原理：LSTM是RNN的一种，通过输入、遗忘和输出门控制历史信息的保留。它可以学习非线性序列关系。文件名中写RNN的课堂示例实际使用LSTM层，因此本文不把它们重复列作独立模型。

实验演变：先演示单变量、多变量与20步预测，再复现DataFactory的Open、Volume、Close输入及25步输出；随后改成半年滚动训练、每天预测次日。后期为匹配PatchTST和TimesFM，统一到两年训练历史，并分别重做20日和32日Close输入版本。早期多步误差不与后期次日误差直接排名。

后期结构：LSTM 32单元 → LSTM 16单元 (ReLU) → Dense 1。每日只用过去数据；内部验证选择训练轮数后，重新初始化模型、优化器和全历史标准化，再拟合全部已知训练样本。



图3 32日输入版本的64次次日预测。绿色为本轮重新训练的LSTM，红色为真实收盘，灰色为前日收盘基准。部分拐点附近出现滞后和较大偏差。

同一64日期	RMSE	MAE
两年训练 + 20日输入	56.28	46.51
两年训练 + 32日输入	55.08	43.43
前日收盘基准	42.31	32.26

结论：32日版本在本次记录中略优于20日版本，两者均未超过前日收盘基准。32日版本有19/64个目标日选到了40轮上限，说明结论受到当前训练预算限制；不能推断所有LSTM配置都无效。

四 PatchTST实验

在本地历史上训练的小型Transformer

原理：PatchTST先把时间序列切成片段，再利用注意力机制学习片段间关系。本项目采用作者官方监督学习实现，没有加载预训练权重。最近20日按长度5、步长3切成6个重叠片段。

实验设置：2层Transformer、4个注意力头、 $d_{\text{model}} = 32$ ，共17,667个参数；采用官方RevIN与LayerNorm。每天在此前两年Close上训练，用相同20日输入与LSTM配对比较。两者使用相同的验证轮数选择规则，但归一化和框架等细节仍有差异。




图4 上图左侧是首次预测的两年训练历史，右侧为64日测试区；下图放大测试区。绿色实线为PatchTST，浅绿点线为同20日输入LSTM，红线为真实收盘，灰线为基准。

同为20日输入	RMSE	MAE
PatchTST	44.94	32.93
LSTM	56.28	46.51
前日收盘基准	42.31	32.26

结论：PatchTST的RMSE比对应LSTM低20.15%，但比基准高6.20%。四个按月区间都优于LSTM，却都没有超过基准。当前支持“小型PatchTST优于这版LSTM”，不支持“注意力机制已带来可交易的预测优势”。

五 TimesFM 2.5实验

冻结预训练权重并直接进行次日预测

原理：TimesFM 2.5是Google的通用预训练时间序列模型。与本地从头训练的PatchTST不同，它已从外部数据学习序列规律；本轮冻结权重，用新输入直接预测，即zero-shot推理。它并非专为上证指数训练。

实验设置：使用官方PyTorch版，固定2025年公开的权重；每次输入32个真实收盘，预测下一交易日。官方点预测取中位数通道。LSTM也按32日输入重新训练，日期、真实值和基准与20日组完全一致。TimesFM没有用左侧两年历史训练或微调。




图5 左侧蓝线仅表示LSTM首次训练历史。TimesFM绿线由64次单步预测连接而成；每次只读取目标日前32个真实收盘。下图与32日LSTM和基准对照。


同为32日输入	RMSE	MAE
TimesFM 2.5	47.04	34.65
LSTM	55.08	43.43
前日收盘基准	42.31	32.26

结论：TimesFM的RMSE比本轮LSTM低14.60%，但比基准高11.18%。方向准确率57.81%，与“始终预测上涨”的方向基准持平（37/64），单凭这个数字也不能证明择时价值。两者的训练信息不同，结果差异不能只归因于架构。

六 综合结论与后续验证

先确认是否存在预测增益 再决定是否增加复杂度

可以确认：在本次已查看的历史区间和固定配置下，修正ARIMA设定、小型PatchTST以及TimesFM预训练推理，都能改善对应对照模型的部分误差；但各自主比较中的整体RMSE仍高于前日收盘基准。



* 仅覆盖部分月份：6月15日起、9月11日止。

图6 两组64日实验的按月RMSE。6月与9月仅覆盖部分月份。PatchTST四个区间均未超过基准；TimesFM仅6月略低于基准，其余区间高于基准。

图像贴近与有效预测之间的区别

指数点位带有很强的前日参照，模型跟随最近点位也可能画出看似贴近的曲线。真正需要检验的是相对基准的新增预测信息。曲线形状、误差下降、方向命中和扣除成本后的盈利，是不同层次的证据。当前实验没有验证可盈利的交易策略。

结论的适用边界

- 样本期较短且反复查看；没有全新的、完全未接触的最终测试期。
- 20日与32日输入不同，预训练与本地训练的信息也不同；不能做全模型的公平架构排名。
- 局部月度胜出和方向准确率不能证明长期稳定优势，当前训练预算与随机种子也有限。

建议的下一步

冻结当前配置与评价规则，在新增、未用于调参的日期继续滚动检验；同时报告点位误差、收益误差和方向基准。若后续建立交易策略，再单独验证换手、成本、滑点与最大回撤。现阶段优先检验信息与验证设计，而不是继续扩大模型。

结果来源与复现记录

ARIMA: sse-arima-improved-20260914内的comparison_results、selected_predictions和protocol。
LSTM与PatchTST: sse-patchtst-20260914内的metrics、predictions和audit。
TimesFM与LSTM: sse-timesfm-20260914内的metrics、predictions、installation和audit。
上述目录均位于项目outputs下；图表从实际JSON重新绘制，完整性校验见本报告附带的report_manifest.json。